

Patch-based Focal Frequency Loss for Image Reconstruction

백창주
(Changju Baek)

지도교수: 임홍기
(Hongki Lim)

요약: 본 연구에서는 Variational Autoencoder(VAE) 기반 생성 모델의 고질적인 문제인 스펙트럼 편향(Spectral Bias)과 고주파 정보 손실을 해결하기 위해, Patch-based Focal Frequency Loss (PB-FFL)을 제안한다. 기존의 전역적(Global) 주파수 분석과 달리, 제안 기법은 Sliding Window 방식을 통해 국소 영역의 주파수와 공간 정보를 동시에 학습함으로써 미세한 텍스처 복원력을 향상시킨다. CelebA-HQ(256×256) 데이터셋 실험 결과, 제안한 손실 함수를 기반으로 학습한 모델은 기존 대비 PSNR 2.16 dB 향상(35.64 dB) 및 LPIPS 약 26% 개선(0.110)을 달성하여 고해상도 이미지 재구성에서의 성능과 유효성을 입증하였다.

Keywords: Image Reconstruction, Patch-based Focal Frequency Loss, Spectral Bias, Variational Autoencoder, VAE

I. 서론

최근 Latent Diffusion Models (LDMs) [1]와 같은 최신 이미지 생성 모델은 고해상도 이미지 합성 분야에 혁신을 이루었다.

이러한 이미지 생성 모델은 연산 효율성을 확보하기 위해 이미지를 저차원의 잠재 공간(Latent Space)로 압축하고 다시 복원하는 Variational Autoencoder (VAE) [2]를 이미지 압축기로 사용한다.

따라서 VAE가 원본의 고주파 디테일을 정교하게 복원하는 성능이 이미지 생성 모델의 성능을 결정한다. 그러나 기존의 VAE 학습에 사용되는 L1 또는 MSE와 같은 픽셀 단위 손실 함수는 평균적인 수렴을 유도하는 특성상 엣지나 텍스처와 같은 고주파 성분을 제대로 학습하지 못하는 경향이 있다.

이는 결과적으로 복원된 이미지가 흐릿해지며, 신경망이 저주파 성분을 먼저 학습하는 스펙트럼 편향(Spectral Bias) [3] 현상에 기인한다.

이를 극복하기 위해 원본 이미지와 이를 압축 후 재구성한 이미지의 주파수 성분의 차이를 반영하려는 Focal Frequency Loss (FFL) [4]가 제안되었으나, 해당 손실 함수는 이미지 전체에 대해 푸리에 변환을 수행하는 전역적(Global) 접근 방식을 사용했다.

이는 이미지 전체 주파수 성분의 분포를 맞추는 데에는 적절하지만, 이미지 전체를 하나의 스펙트럼으로 변환하는 과정에서 주파수 정보의 공간적 분포(Spatial Distribution)가 무시되는 경향이 있어 국소 영역(Local Region)의 디테일을 정교하게 복원하는 데에는 한계가 있다.

이에 대한 해결책으로 Isola et al. [5]은 국소 패치 단위의 접근이 고주파 정보 복원에 효과적임을 보였다.

또한, 최근 VAE 구조에 STFT(Short-Time Fourier Transform)를 접목하여 국소 주파수 분석의 유효성을 입증한 연구 [6]에 착안하여, 본 연구에서는 이러한 접근들을 고해상도 이미지 복원 문제로 확장하여 VAE의 복원 능력을 극대화하기 위해 Patch-based Focal Frequency Loss (PB-FFL)를 제안한다.

슬라이딩 윈도우(Sliding Window) 방식으로 중첩된 국소 영역에 대해 푸리에 변환을 수행하여 주파수 손실을 계산하는 방식을 사용하며, 경계에서 발생할 수 있는 불연속성을 방지함과 동시에 고주파 성분과 공간적 위치 정보를 포착하도록 설계하였다.

결과적으로 본 연구는 제안된 주파수 손실 함수를 통해 고주파 성분 디테일 복원 성능을 개선하였으며, 모델 확장을 통한 확장성 검증과 함께 기존 대비 2.16 dB 향상된 PSNR 35.64 dB와 LPIPS [7] 0.110(약 26% 향상)을 달성하였다.

II. 이론적 배경

1. Variational Autoencoder (VAE)

Variational Autoencoder (VAE) [2]는 이미지 생성 모델에 널리 사용되며, 최근 LDM 모델 등에서 고해상도 이미지를 효율적으로 처리하기 위한 압축 모델로 널리 사용된다. VAE는 학습하는 데이터의 우도(Likelihood) 대신 ELBO(Evidence Lower Bound)를 최대화하는 방식으로 학습한다.

일반적으로 이미지 재구성(Reconstruction) 성능을 위해 L1 또는 L2(MSE) 손실 함수를 사용한다.

본 연구에서는 L1 손실 함수를 기준으로 하였으며, 수식으로 정의된 VAE의 목적 함수는 다음과 같이 정의된다.

$$\mathcal{L}_{VAE} = \mathcal{L}_{recon} + \beta \cdot \mathcal{L}_{KL} \quad (1)$$

$$\mathcal{L}_{recon} = \|x - \hat{x}\|_1 \quad (2)$$

$$\mathcal{L}_{KL} = D_{KL}(q_{\phi}(z|x) \| p(z)) \quad (3)$$

$\mathcal{L}_{recon}$ 은 입력 이미지 x 와 재구성 이미지 $\hat{x}$ 사이의 L1(또는 L2) 거리를 의미하며, $\mathcal{L}_{KL}$ 은 잠재 분포와 사전 분포 간의 유사도인 KL Divergence를 의미한다.

그러나 이러한 픽셀 기반 손실 함수들은 주로 고주파 성분이 강한 엣지, 텍스처 정보의 평균값을 통해 예측하려는 경향이 있어 고주파 정보가 일부 손실되는 문제가 있다.

이는 신경망이 저주파 성분을 우선적으로 학습하는 스펙트럼 편향(Spectral Bias)[3] 현상과도 밀접한 관련이 있다.

2. 주파수 기반 학습

이러한 픽셀 기반 손실 함수의 한계를 극복하기 위해, 주파수 도메인의 정보를 학습에 활용하려는 연구들이 활발히 진행되었다.

Jiang et al. [4]은 푸리에 변환(FFT)을 통해 원본과 재구성 이미지의 주파수 스펙트럼 거리를 최소화하는 Focal Frequency Loss (FFL)을 제안하였다.

FFL은 학습하기 어려운 고주파 성분에 동적으로 가중치를 부여하여 디테일 복원 성능을 개선하였다. 하지만 기존의 FFL 방식은 이미지 전체에 단일 FFT를 수행하는 전역적(Global) 방식을 채택하였다.

이는 이미지 전반의 주파수 성분을 비교하기 때문에 특정 주파수 성분이 존재하는 위치에 대한 공간적 정보를 고려하지 않는다. 따라서 눈, 코, 입과 같이 특정 위치에 고유한 디테일이 중요한 얼굴이나 머리카락 이미지 복원에서는 그 성능이 제한적이다.

3. 공간-주파수 분석과 윈도우 함수

전역적 푸리에 변환은 주파수 정보의 시간(공간)적 위치를 파악하지 못하는 한계가 있다. 이를 해결하기 위해 윈도우(Window)를 이동시키며 국소(Local) 구간을 분석하는 Short Time Fourier Transform이 표준적으로 사용된다. 이때 신호를 단순히 절단하면 경계면의 불연속성으로 인해 정확도가 저하된다. 따라서 Hann Window와 같은 윈도우 함수를 적용하여 경계를 평활화(Smoothing) 하는 과정을 적용한다.

본 연구에서는 이를 2차원으로 확장하는 방법을 적용한다.

이 방식을 통해 모델이 고주파 성분을 정확한 위치와 함께 학습하도록 유도하였다.

III. 본론

1. Network Architecture

네트워크 구조는 Encoder, Latent Space, Decoder로 구성된다. 입력 이미지 $x \in \mathbb{R}^{H \times W \times 3}$ 는 인코더를 통과하며 다운샘플링한다. 네트워크는 총 3단계의 DownEncoderBlock2D를 통해 이미지를 잠재 공간으로 압축한다. 하이퍼 파라미터 탐색을 위한 Base Model은 [64, 128, 256]의 채널을 선정하였다.

최종 성능 검증을 위한 Enhanced Model은 Base Model의 2 배인 [128, 256, 512] 채널을 가지도록 설계하였다. 각 인코더 블록은 ResNet 구조와 Group Normalization으로 구성되어 특징을 효율적으로 추출한다.

1.1. 병목 구간 (Bottleneck & Mid-Block)

이미지가 최저 해상도인 병목 구간에 도달하면 모델은 Self-Attention이 포함된 MidBlock을 수행하며, 이 단계에서는 압축된 특징 맵(Feature Map) 상에서 이미지의 전역적인 문맥(Global Context) 정보를 포착한다.

1.2. 잠재 공간 (Latent Space)

인코더의 출력은 $\frac{H}{8} \times \frac{W}{8} \times 4$ 크기의 잠재 벡터 z 로 매핑된다. 채널이 4개인 이유는 LDM[1]에서 사용하는 이미지 압축 모듈의 표준 설정을 따른 것이다.

학습 과정에서 Reparameterization Trick을 통해 잠재 벡터 z 를 샘플링한다. 정의된 수식은 다음과 같다.

$$z = \mu + \sigma \odot \epsilon, \epsilon \sim \mathcal{N}(0, I) \quad (4)$$

이는 인코더가 예측한 평균(μ)과 표준편차(σ)를 통해 미분 불가능한 샘플링 연산을 미분 가능한 형태로 변환한다. 디코더는 잠재 벡터 z 를 입력받아 다시 원본 해상도의 이미지로 재구성한다.

본 연구에서는 L1 손실 함수만을 사용하여 학습한 모델을 Baseline으로 정의하였다.

2. Patch-based Focal Frequency Loss (PB-FFL)

선행 연구[6]에서 제시한 주파수-공간 분석(Spectral-Spatial Analysis)의 이점을 반영하여 이미지의 국소(Local) 주파수 특성을 공간 위치 정보와 함께 학습하기 위해 슬라이딩 윈도우 (Sliding Window) 기반의 새로운 주파수 손실 함수를 제안한다.




그림 1. PB-FFL의 계산 과정 시각화

계산 과정은 패치 추출, 윈도우 함수 적용, 동적 가중치 적용의 3 단계로 구성된다

2.1. Sliding Window Extraction

단순한 그리드 분할 방식 대신 공간적 연속성을 보존하기 위해 슬라이딩 윈도우(Sliding Window) 방식을 적용한다. 구현상의 효율을 위해 Pytorch의 unfold 연산을 사용하여 입력 이미지 x 와 재구성 이미지 $\hat{x}$ 를 패치 단위로 벡터화 하였다. 패치의 크기 $K=32$, Stride $S=16$ 으로 설정하였다. 서로 인접한 위치에서의 패치가 일부 중첩되도록 추출하여 패치 경계에서의 정보 손실을 최소화하였다.

2.2. Hann Window & FFT

추출한 패치에 대해 곧바로 푸리에 변환을 수행할 경우, 경계면의 불연속성으로 인해 고주파 노이즈가 발생하게 되므로, 2차원 Hann Window를 각 패치에 대해 Elementwise 곱을 취한 다음 FFT를 수행하며 수학적 정의는 다음과 같다.

$$P(u, v) = \mathcal{F}(p(x, y) \odot W_{Hann}(x, y)) \quad (5)$$

여기서 (x, y) 는 패치 내의 좌표, (u, v) 는 주파수 도메인에서의 좌표를 의미하며, W_{Hann} 의 정의는 다음과 같다.

$$W_{Hann}(i, j) = 0.5 \left(1 - \cos\left(\frac{2\pi i}{K-1}\right)\right) \cdot 0.5 \left(1 - \cos\left(\frac{2\pi j}{K-1}\right)\right) \quad (6)$$

이 과정은 패치 가장자리의 값을 부드럽게(smooth)하여 연산의 정밀도를 높인다.

2.3. Dynamic Weighting

모델이 학습 과정에서 고주파 성분에 집중하도록 유도하기 위해 주파수 차이에 비례하는 동적 가중치를 부여한다. 먼저 원본 이미지 스펙트럼 P_x 와 재구성 이미지 스펙트럼 $P_{\hat{x}}$ 간의 거리 $d(u, v)$ 를 다음과 같이 정의한다.

$$d(u, v) = |P_x(u, v) - P_{\hat{x}}(u, v)| \quad (7)$$

정의한 $d(u, v)$ 에 비례하여 동적 가중치 $\omega(u, v)$ 을 계산하며 정의는 다음과 같다.

$$\omega(u, v) = \log(d(u, v)^\alpha + 1) \quad (8)$$

여기서 α 는 주파수 민감도를 조절하는 인자이다. 본 연구에서는 $\alpha = 1.0$ 을 사용하였으며, α 가 클수록 오차가 큰 주파수(주로 고주파)에 가중치가 급격히 커지게 된다.

과도한 가중치로 인한 학습 불안정을 방지하기 위해 선형적인 스케일을 사용하였다.

2.4. 손실 함수 수식 정의

손실 함수 $\mathcal{L}_{PB-FFL}$ 는 다음과 같이 정의된다.

$$\mathcal{L}_{PB-FFL} = \frac{1}{N} \sum_{p=1}^N \frac{1}{K^2} \sum_{u,v} \omega_p(u, v) d_p(u, v)^2 \quad (9)$$

이때 N 은 총 패치의 개수, p 는 각 패치의 인덱스를 의미하며, K^2 는 각 패치 내의 주파수 성분의 총 개수($K \times K$)를 의미한다. 이를 통해 패치 크기에 따른 손실 값을 정규화하는 역할을 수행한다.

3. 최종 목적 함수 (Total Objective Function)

최종 목적 함수는 픽셀 단위 정확도를 위한 L1 손실, 국소 영역의 고주파 정보(엣지, 텍스처) 복원을 위한 PB-FFL, 잠재 공간 정규화를 위한 KL Divergence 항의 가중 합으로 정의된다.

$$\mathcal{L}_{Total} = \mathcal{L}_{recon} + \lambda_{freq} \cdot \mathcal{L}_{PB-FFL} + \beta \cdot \mathcal{L}_{KL} \quad (10)$$

$\mathcal{L}_{recon}$ 와 $\mathcal{L}_{KL}$ 는 이론적 배경 2.1 절에서 소개한 VAE의 목적 함수와 동일하며, λ_{freq} 는 $\mathcal{L}_{recon}$ 와 주파수 손실 간의 균형을 맞추기 위한 하이퍼 파라미터이다.

본 연구에서는 $\lambda_{freq} = 0.5$ 를 사용하여 과도한 고주파 강조로 인해 주파수 손실이 전체 학습을 방해하지 않고 픽셀 기반 재구성을 보조하는 역할을 하도록 설정하였다. 이는 전체적인 이미지 구조의 안정성을 유지하면서 세부 디테일 표현을 향상시키기 위함이다.

β 는 잠재 공간의 정규화 강도를 조절한다. 본 연구는 이미지 재구성 품질을 최우선으로 하므로, β 를 매우 작은 값($\beta = 1e-6$)으로 설정하여 정규화로 인한 이미지 선명도 저해를 방지하였다.

IV. 실험 및 결과

본 장에서는 Patch-based Focal Frequency Loss(PB-FFL)의 유효성을 검증하기 위해 수행한 실험 설정과 결과를 제시하고 분석한다. CelebA-HQ resized (256 × 256) 데이터셋을 통해 제안한 모델의 이미지 재구성 성능을 평가하였으며, 기존 손실 함수와의 비교 및 모델 용량 확장에 따른 추가 실험을 통해 제안한 손실 함수의 성능을 입증한다.

1. 실험 환경

1.1. Dataset

실험에는 고해상도 얼굴 이미지 데이터셋인 CelebA-HQ resized (256 × 256) 을 사용하였다. 이는 원본 CelebA-HQ를 256 × 256 해상도로 전처리된 총 30,000 장의 고화질 이미지 데이터셋이다. KaggleHub을 통해 Dataset을 학습에 사용하였으며, 전체 데이터를 9:1의 비율로 훈련(Train) 및 검증(Validation) Set으로 분할하였다. 모든 이미지는 텐서로 변환 후 [-1, 1]의 범위로 정규화 하여 네트워크 학습에 사용하였다.

1.2. 구현 세부사항

본 연구의 모델은 Pytorch Framework와 Hugging Face Diffuser 라이브러리를 기반으로 구현하였다.

학습은 Google Colab 환경의 NVIDIA A100 GPU에서 수행했다. AutoencoderKL 구조를 사용하되 가중치는 사전 학습 없이 학습하였으며 학습의 안정성을 위해 Mixed Precision (FP16) 연산을 적용하였다.

최적화 알고리즘은 Adam Optimizer를 사용하였으며, Learning Rate는 1e-4, Batch size는 64로 설정하여 총 20Epochs 동안 학습하였다.

비교 실험을 위한 Baseline 모델은 PB-FFL 가중치를 0.0으로 설정하고, L1 손실과 KL 손실($\beta=1e-6$ 으로 설정)만을 사용하여 학습을 진행했다.

3.1절에서 언급한 [64, 128, 256]의 채널을 가지는 Base Model에서 좋은 성능을 보이는 하이퍼 파라미터를 탐색하였으며, 최고 성능을 보이는 지점에서 채널을 2배로 모델 용량을 늘린 Enhanced Model에서의 L1 손실 함수와 제안한 PB-FFL를 적용한 손실 함수의 성능을 비교하였다.

2. 평가 지표

이미지 재구성 성능을 평가하기 위해 픽셀 단위 정확도와 인간의 시각적 품질을 종합적으로 평가하기 위해 세 가지 지표를 도입하였다.

2.1 PSNR (Peak Signal-to-Noise Ratio)

PSNR은 신호(Signal)의 최대 가능 전력과 잡음(Noise) 전력의 비율을 데시벨(dB) 단위로 나타낸 지표로, 영상 화질 평가에 널리 사용되며 다음과 같이 정의된다.

$$PSNR = 10 \cdot \log_{10} \left(\frac{MAX_I^2}{MSE} \right) \quad (11)$$

정의된 식과 같이 MSE(Mean Squared Error)에 반비례한 계산으로, 픽셀 값의 물리적 차이를 정량화 하는데 효과적이다.

그러나 PSNR은 이미지가 흐릿하게 복원되어도 픽셀 값의 평균 오차가 작으면 높은 점수를 산출하는 경향이 있어, 실제 인간이 느끼는 선명도와는 괴리가 있을 수 있다.

2.2 SSIM (Structural Similarity Index Map)

SSIM은 인간의 시각 시스템이 이미지의 구조적 정보(Structural Information)에 민감하다는 점에 착안하여 개발된 지표이다. 단순히 픽셀 차이를 계산하는 대신, 이미지 휘도(Luminance), 대비(Contrast), 구조(Structure) 3가지 요소를 독립적으로 비교하여 유사도를 측정한다. 이는 PSNR의 한계를 보완하여 국소 영역에서의 패턴이 보존 여부를 평가하는데 적합하다.

2.1 LPIPS (Learned Perceptual Image Patch Similarity)

앞선 두 지표가 통계적 수치에 의존하는 반면, LPIPS [7]는 딥러닝 모델(AlexNet, VGG 등)을 통해 추출된 특징 맵(Feature map) 간의 거리를 계산한다. Zhang et al. [7]은 LPIPS가 사람의 시각적 판단과 가장 높은 상관관계를 보임을 입증하였으며, 본 연구의 핵심 목표인 고주파 성분 복원은 픽셀 수치보다 시각적 유사성이 중요하기 때문에 LPIPS 값이 낮을수록 본 연구에서 제안하는 방법론의 유효성을 잘 나타낸다.

3. Ablation Study & Optimization

앞서 언급한 [64, 128, 256]의 채널 수를 가지는 Base Model을 기반으로 주파수 손실 가중치 λ_{freq} 와 패치 크기(K)의 변화에 따른 성능을 분석하였으며, Baseline은 L1 손실 함수($\lambda_{freq} = 0.0$)을 사용한다.

표 1. 하이퍼 파라미터 탐색 결과

λ_{freq}	K	PSNR ↑	SSIM ↑	LPIPS ↓
0.0	-	32.12	0.914	0.158
0.2	16	32.72	0.916	0.157
0.5	16	32.99	0.920	0.150
1.0	16	32.73	0.914	0.145
0.5	32	34.60	0.940	0.124

실험 결과, $\lambda_{freq} = 0.2$ 에서는 기존 L1 손실 함수만을 사용하는 Baseline 모델과 큰 차이가 없었다.

($\lambda_{freq} = 0.5, K = 32$)에서 가장 우수한 성능 (LPIPS = 0.124) 을 보였다. 이는 너무 작은 패치 크기($K = 16$)보다 32×32 크기의 패치가 국소 영역에 대한 주파수 특징을 포착하기에 더 적합하며, ($\lambda_{freq} = 1.0$)에서 PSNR과 SSIM이 악화되는 것으로 보아 과도한 주파수 가중치는 오히려 학습 안정성을 저해하였다.

따라서 최적화된 설정($\lambda_{freq} = 0.5, K = 32$)을 최종 확장 모델(Enhanced Model)에 적용하였다.

4. 최종 평가 및 확장성 검증

앞선 실험에서 도출한 설정을 채널을 2배 늘린 Enhanced 모델을 학습하여 최종 성능을 평가한다.

표 2. 채널 확장에 따른 성능 비교

Channel	Loss	PSNR↑	SSIM↑	LPIPS↓
Base	L1 (Baseline)	32.12	0.914	0.158
	Ours	34.60	0.940	0.124
Enhanced	L1 (Baseline)	33.48	0.93	0.150
	Ours	35.64	0.95	0.110

[표 2]에서 볼 수 있듯이, 모델의 채널 용량을 2 배로 확장하였을 때, Enhanced 모델에서 PB-FFL 손실 함수를 사용하여 학습한 모델은 Baseline 대비 PSNR 2.16dB, LPIPS 약 26% 개선이라는 뚜렷한 성능 향상을 기록하였다.

이는 제안 기법이 모델의 크기가 커져도 유효하며, 픽셀 기반 학습의 한계를 효과적으로 보완함을 입증한다.

5. 시각화 및 분석

공간 제약으로 인해 확대된 그림 2, 그림 3 이미지는 부록(Appendix)에 추가로 첨부하였으며 추가적인 시각화 이미지를 첨부하였다.

정량적 지표의 향상이 실제 지각적 품질 향상으로 이어지는지 검증하기 위해 테스트 데이터셋에 대한 재구성 이미지와 에러 맵(Error Map)을 분석하였다.




그림 2. 재구성 결과 시각화

[그림 2]는 Baseline(L1)과 제안하는 PB-FFL 모델의 재구성 결과를 확대하여 시각화 한 그림이다.

Baseline 모델은 전반적인 구조는 복원하지만, 눈동자의 반사광이나 머리카락의 결과 같은 고주파 영역에서 블러(Blur) 현상이 발생하여 고주파 디테일이 일부 소실되는 모습을 보였다.

반면, 제안한 PB-FFL을 적용하여 학습한 모델은 이러한 텍스처 정보를 보존하고 있는 모습이다.




그림 3. 에러 맵(Error Map)

[그림 3]은 모델의 재구성 결과와 원본(Ground Truth) 간의 픽셀 단위 차이를 시각화 한 Error Map이다.

Baseline(L1)의 에러 맵을 보면 눈과 입, 머리카락 등 엣지(Edge)가 많은 영역에서 높은 오차 값이 집중적으로 분포함을 알 수 있다. 이는 L1 손실 함수가 고주파 성분을 효과적으로 학습하지 못함을 시각적으로 보여준다. 반면, 우측의 제안 모델의 에러 맵은 Baseline에 비해 전반적인 오차 수준이 낮으며, 특히 고주파 정보가 많은 영역에서의 오차가 눈에 띄게 감소하였다. 이는 주파수 영역에서의 손실 함수가 이미지의 국소 디테일 복원에 기여하였음을 여실히 보여준다.

V. 결론

1. Summary & Contributions

본 연구에서는 고해상도 이미지 재구성 작업에서 픽셀 기반 손실 함수(L1 Loss)가 갖는 고질적인 문제인 스펙트럼 편향(Spectral Bias)과 이로 인한 고주파 정보의 소실 문제를 해결하기 위해, 국소 영역(Local Region)의 주파수 정보를 효과적으로 포착하는

Patch-based Focal Frequency Loss (PB-FFL)를 제안하였다.

이미지의 공간적 특성을 고려하여 Sliding Window 기반의 주파수 도메인으로의 변환을 수행하고, 주파수 성분 오차에 따른 동적 가중치 할당 메커니즘을 결합함으로써, 모델이 학습하기 어려운 미세한 엣지(Edge)와 텍스처와 같은 고주파 정보를 효과적으로 복원하도록 유도하였다.

CelebA-HQ resized (256 × 256) 데이터셋을 활용한 실험 결과, 제안 모델은 정량적 및 정성적 평가 측면 모두에서 유의미한 성과를 거두었다.

첫째로, 뚜렷한 재구성 성능의 개선을 달성하였다. 본 연구에서 제안하는 PB-FFL을 도입한 모델은 Baseline(L1) 대비 PSNR을 2.16dB 향상시켰으며, 특히 인간의 시각적 인지 특성을 반영한 지각적 지표인 LPIPS를 약 26% (0.150 → 0.110) 개선하였다.

또한, 에러 맵(Error Map) 분석을 통해 눈동자, 머리카락 등 고주파 정보가 밀집된 국소 영역에서의 오차가 현저히 감소하였음을 시각적으로 입증하였다.

둘째로, 모델 확장에 따른 강건함(Robustness)를 검증하였다. 연산 효율성을 위해 경량화된 Base 모델에서 최적화한 하이퍼 파라미터 ($\lambda_{freq} = 0.5, K = 32$) 설정에서 채널 수를 2배로 늘린 Enhanced 모델에 그대로 적용하였음에도 불구하고 추가적인 하이퍼 파라미터 튜닝 없이 Baseline(L1) 대비 월등한 성능 향상을 기록하였다. 이는 제안하는 손실 함수가 모델의 용량(Capacity) 변화에 구애받지 않고 범용적으로 적용될 수 있는 효과적인 방법론임을 시사한다.

결론적으로, 본 연구에서 제안하는 Patch-based Focal Frequency Loss (PB-FFL)는 기존 픽셀 기반의 손실 함수의 한계를 극복하고 이미지의 안정적인 재구성과 지각적 품질을 동시에 확보할 수 있는 효과적인 방법론임을 확인하였다.

2. 본 연구의 한계점

본 연구의 성과에도 불구하고, 기술적인 한계점과 개선의 여지는 여전히 존재한다.

첫 번째로 연산 비용(Computational Cost)의 증가이다. Sliding Window 방식은 이미지 전체를 한 번에 주파수 도메인으로 변환하는 Global FFT 방식이나 단순한 픽셀 차이 계산에 비해 물리적인 연산량이 많다.

기존 L1 손실 함수는 이미지 내 모든 픽셀을 1회씩 연산하는 반면, PB-FFL 손실 함수는 Stride가 패치 크기보다 작은 Sliding Window 방식을 채택하여 중복된 연산이 발생한다. 본 실험 환경 (256×256 이미지, 32×32 패치, Stride 16)을 기준으로 할 때, L1 대비 약 3.5배 많은 픽셀 연산량이 요구되며, 각 패치마다 수행되는 FFT 연산을 감안한다면, 비록 벡터 연산을 통해 이를 최적화하였으나, 이러한 학습 단계에서의 메모리 사용량 증가는 본 연구에서 실험한 256×256 보다 큰 고해상도 이미지 데이터셋으로의 확장에 제약 요인이 될 수 있다.

두 번째로, 고정된 패치 크기의 한계이다. 본 연구에서는 32×32 크기의 패치가 최적의 성능을 보였으나, 이미지 내 객체(Object) 크기가 다양하거나 배경이 지나치게 복잡한 경우에는 고정된 크기의 Window가 특징을 온전히 포착하지 못할 가능성이 있다.

3. Future Work

향후 연구에는 본 연구의 한계점을 보완하고 제안 기법의 효용성을 높이기 위해 다음과 같은 연구를 수행하고자 한다.

첫째, 최신 생성 모델로의 적용 및 확장이다. 본 연구에서는 VAE 기반의 이미지 재구성에 집중하였으나,

향후에는 이를 Latent Diffusion Model(LDM)이나 Diffusion Transformer (DiT)와 같은 최신 이미지 생성 모델의 학습 과정에 통합하여 생성 모델들이 잠재 공간(Latent Space)에서 압축된 정보를 복원할 때 발생하는 미세한 고주파 정보 소실 문제를 PB-FFL이 효과적으로 보완할 수 있을 것으로 기대되며, 이를 통해 생성 모델의 디테일 표현력을 강화할 수 있을 것이다.

둘째, 적응형(Adaptive) 패치 구조의 도입이다. 현재 고정된 패치 크기 방식을 개선하여, 이미지 내 객체의 크기나 구조적 복잡도에 따라 윈도우 크기를 동적으로 조절하는 방법을 연구한다면 더욱 정교한 고주파 디테일 복원이 가능할 것이다.

셋째, 데이터셋 확장을 통한 범용성 검증이다. 현재의 인물 얼굴 데이터셋(CelebA-HQ) 뿐만 아니라, 자연 풍경이나 건축물, 사물 등 다양한 도메인의 데이터셋에 본 연구에서 제안한 방법론을 적용함으로써, PB-FFL의 범용성과 다양한 환경에서의 성능 및 안정성을 추가적으로 검증할 계획이다.

참고문헌

- [1] R. Rombach, A. Blattmann, D. Lorenz, P. Esser and B. Ommer, "High-resolution image synthesis with latent diffusion models," in Proc. of IEEE/CVF Conf. on Computer Vision and Pattern Recognition (CVPR), pp. 10684–10695, 2022.
- [2] D. P. Kingma and M. Welling, "Auto-encoding variational bayes," arXiv preprint arXiv:1312.6114, 2013.
- [3] N. Rahaman, A. Baratin, D. Arpit, F. Draxler, M. Lin, F. Hamprecht, Y. Bengio and A. Courville, "On the spectral bias of neural networks," in Proc. of Int. Conf. on Machine Learning (ICML), pp. 5301–5310, 2019.
- [4] L. Jiang, B. Dai, W. Wu and C. C. Loy, "Focal frequency loss for image reconstruction and synthesis," in Proc. of IEEE/CVF Int. Conf. on Computer Vision (ICCV), pp. 13919–13929, 2021.
- [5] P. Isola, J. Y. Zhu, T. Zhou and A. A. Efros, "Image-to-image translation with conditional adversarial networks," in Proc. of IEEE Conf. on Computer Vision and Pattern Recognition (CVPR), pp. 1125–1134, 2017.
- [6] V. Dalal, "Short-Time Fourier Transform for deblurring Variational Autoencoders," arXiv preprint arXiv:2401.03166, 2024.
- [7] R. Zhang, P. Isola, A. A. Efros, E. Shechtman, and O. Wang, "The unreasonable effectiveness of deep features as a perceptual metric," Proceedings of the IEEE Conference on Computer Vision and Pattern Recognition (CVPR), pp. 586–595, 2018.



백 창 주

2020년 ~ 현재 인하대학교

전기전자공학부 재학.

2025년 2월 졸업 예정.

관심분야는 인공지능, 컴퓨터비전

부록




그림 A.1. 그림 2의 확대 이미지.




그림 A.2. 그림 3의 확대 이미지.




그림 A.4. 추가적인 테스트 데이터셋에 대한 재구성 결과 확대 비교.




그림 A.4. 추가적인 테스트 데이터셋에 대한 에러 맵(Error Map) 결과.